

# Cours 20: Séries Temporelles


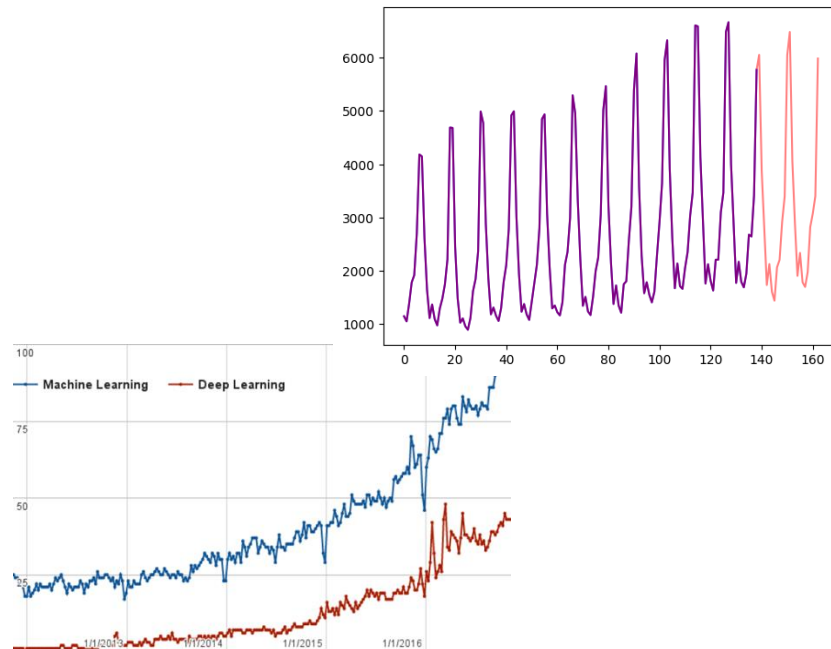
IFT 6758



# Motivation




- Exemples de séries temporelles

- Valeurs boursières
- Variables économiques
- Température (météo)
- Tremblement de terre
- Demande/consommation d'énergie



# Méthodes Auto-Regressives

- La variable au temps  $t+1$  est une fonction de  $x_t$ 
  - $X_{t+1} = f(x_t, w)$
  - But: apprendre les paramètres  $w$  du modèle pour prédire le futur.
- Utilise l'hypothèse de Markov
  - L'état  $x_t$  contient assez d'information pour prédire l'état suivant.





# Méthodes Autoregressives

- Modèles
  - Il est possible d'utiliser de nombreux modèles vu en classe pour modéliser la fonction  $f$ .
  - Modèles linéaires, réseaux de neurones, transformers
- Hypothèse de Markov d'ordre  $q$  (vu en langage)
  - Les états  $x_{t-q+1}, \dots, x_t$  sont suffisants pour prédire  $x_{t+1}$
  - Une certaine quantité de l'historique est suffisant pour prédire le futur.

# À quel point à-t-on besoin du passé?

- $q$  est une hyperparamètre du modèle
  - Il va dépendre du jeu de données et de l'application
  - Plus  $q$  est grand, plus le modèle a de paramètres
  - Important d'avoir le bon ordre de grandeur.
- Exemples
  - Prédire la météo: (de 2 jours à 200 ans)
  - Consommation énergétique (cycles journaliers et hebdomadaires)
  - Actions boursières (cycles trimestriels).



Apprentissage hors  
ligne (offline learning)

# Méthodes d'apprentissage

- *Modèles linéaires autoregressifs*

$$Y_t = \gamma + \sum_{i=1}^q a_i Y_{t-i} + \epsilon_t$$

Avec:

- $\epsilon_t$  est le bruit dans les mesures.
- $a_0, a_1, \dots, a_q$  sont les coefficients autoregressifs.
- $Y_t$  est la variable observée.

# Exemple:

Caractéristiques:

$Y_{t-1}, \dots, Y_{t-q}$

Étiquette:

$Y_t$

Paramètres:

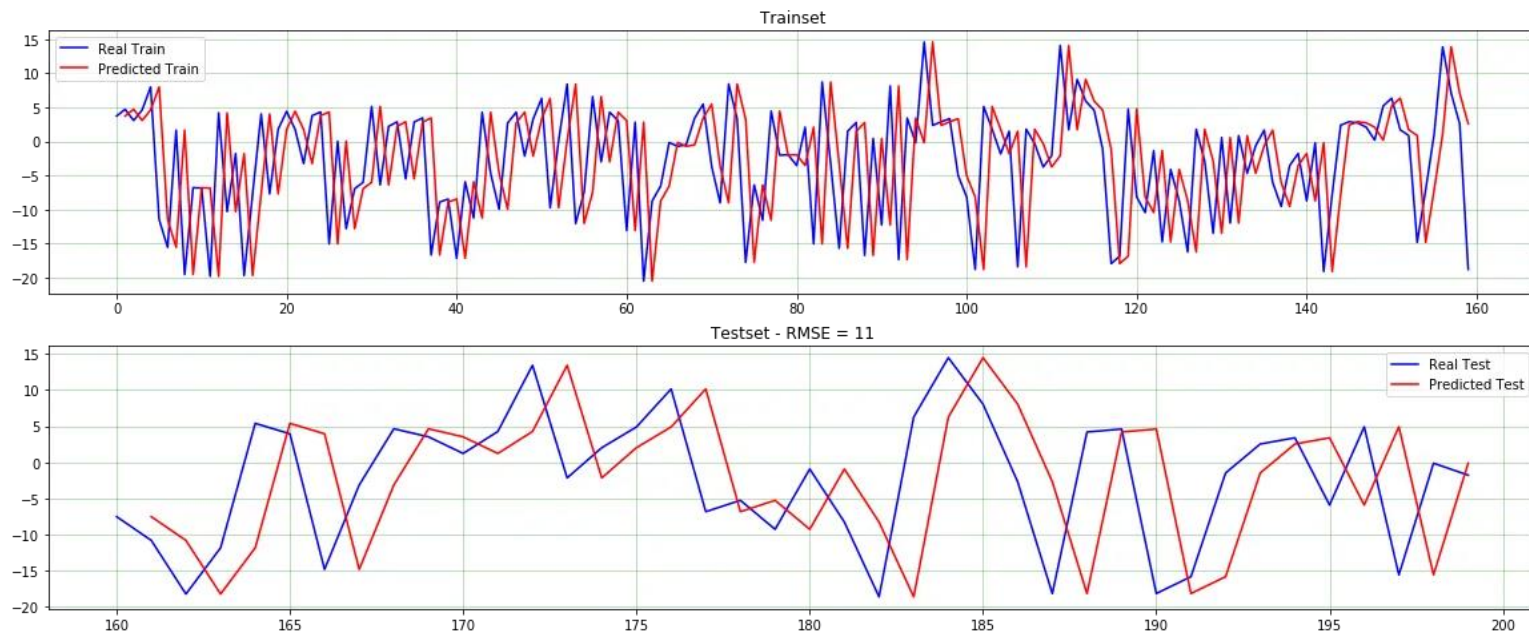
$a_i$



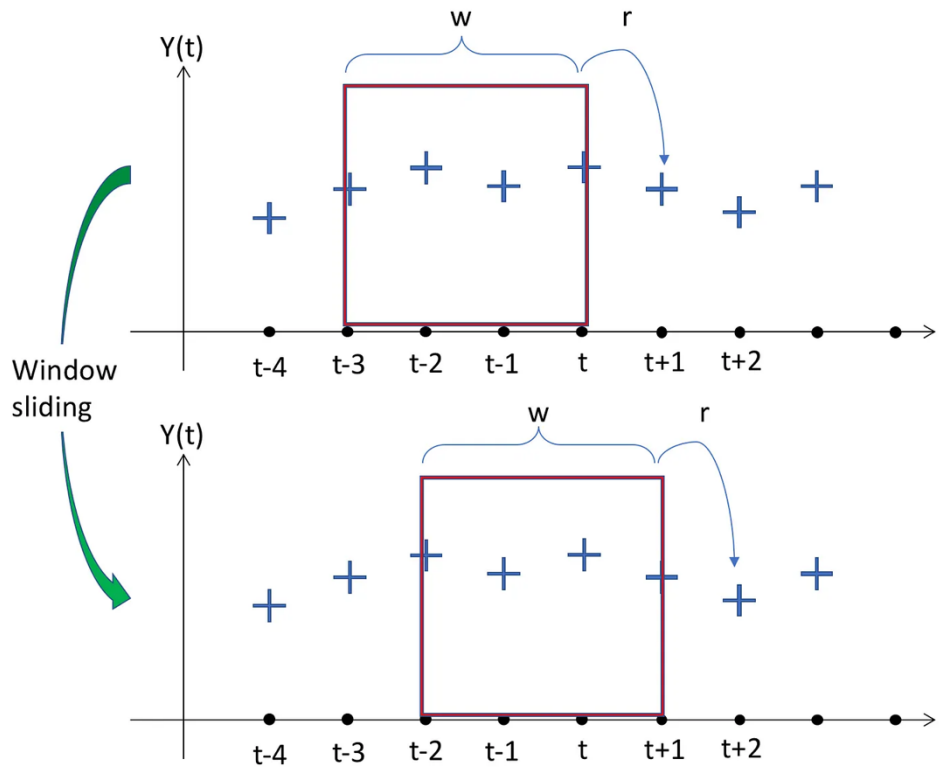


# Le modèle le plus simple: $\hat{y}_t = y_{t-1}$

Actual vs Predicted - Baseline Model




# Example



# Modèle linéaire autoregressif

Actual vs Predicted - Multiple Linear Regression



## Encore mieux: ARMA et ARIMA

- ARMA est la combinaison d'un modèle Auto-Regressive et d'un modèle (MA)

Moving Average:

$$Y_t = \gamma + \sum_{i=1}^q a_i Y_{t-i} + b_i \epsilon_{t-i} + \epsilon_t$$


## ARMA et ARIMA



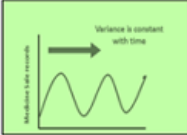
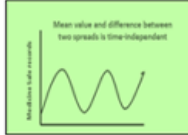

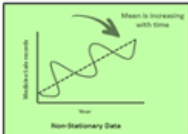

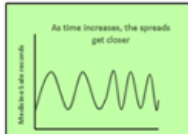
$$Y_t = \gamma + \sum_{i=1}^q a_i Y_{t-i} + b_i \epsilon_{t-i} + \epsilon_t$$

- ARMA is est idéal pour les séries stationnaires. **ARIMA** a été développé pour fonctionner sur les séries non-stationnaires.
  - AR → Utilise les valeurs passées pour prédire le futur.
  - MA → Utilise les erreurs passées pour prédire l'erreur future.
  - I==> Transformation de l'entrée Y pour la rendre plus stationnaire.

# Stationnarité d'une série temporelle

Définition : une séquence de variables aléatoires est stationnaire si sa distribution est invariante au décalage temporel.



	MEAN	Variance	Covariance
Stationary 	 Mean is constant with time Stationary Data	 Variance is constant with time	 Mean value and difference between two spreads is time-independent
Non-Stationary 	 Mean is increasing with time Non-Stationary Data	 Variance is varying with time	 As time increases, the spreads get closer

# Modèles de Markov avec variables cachées

- *La non-stationnarité apparaît lorsque l'on manque d'information*
- Nous observons seulement l'état  $Y$ .

$$\mathbf{X}_{t+1} = \mathbf{B}\mathbf{X}_t + \mathbf{U}_t,$$

$$Y_t = \mathbf{A}\mathbf{X}_t + \epsilon_t$$


- $\mathbf{X}_t$  is an  $n$ -dimensional state vector.
- $Y_t$  is an observed stochastic process.
- $\mathbf{A}$  and  $\mathbf{B}$  are model parameters.
- $\mathbf{U}_t$  and  $\epsilon_t$  are noise terms.

# Modèles de Markov avec variables cachées

- *La non-stationnarité apparaît souvent lorsque l'on manque d'information*

Variable Cachée:  
(imaginons que nous  
n'avons pas accès à  
la météo)

Variable Observée:





# Modèles de Markov avec variables cachées

- *La non-stationnarité apparaît lorsque l'on manque d'information*
- Nous observons seulement l'état  $Y$ .

$$\mathbf{X}_{t+1} = \mathbf{B}\mathbf{X}_t + \mathbf{U}_t,$$

$$Y_t = \mathbf{A}\mathbf{X}_t + \epsilon_t$$

- La plupart du temps:
  - On ne peut pas observer  $X_t$ .
  - On sait qu'il existe (donc on va essayer de l'apprendre)
  - Principe des RNN (Réseaux neuronaux récurrents) (Les RNNs sont **Non linéaires**)

# Généralement, deux scénarios

## Scénario Stochastique

- Hypothèse que la distribution est stationnaire (ou avec une non-stationnarité simple)
- Mesure de performance: perte moyenne

## Scénario en-ligne:

- Pas d'hypothèse sur la distribution
- Mesure de performance: regret.
- Recherche active: (Cesa-Bianchi and Lugosi, 2006; Anava et al. 2013, 2015, 2016; Bousquet and Warmuth, 2002; Herbster and Warmuth, 1998, 2001; Koolen et al., 2015).

Apprentissage en-  
ligne (online learning)

# Apprentissage en-ligne

- Apprentissage en ligne:

- On reçoit l'entrée  $x_t$
- On choisit un classifieur  $h_t$
- L'environnement choisit  $y_t$
- On souffre de la perte  $L$

- Objectif:

- Minimiser le regret.
- On ne veut plus minimiser la perte mais la somme des pertes.

- For  $t = 1$  to  $T$  do

- player receives  $x_t \in \mathcal{X}$ .
- player selects  $h_t \in H$ .
- adversary selects  $y_t \in \mathcal{Y}$ .
- player incurs loss  $L(h_t(x_t), y_t)$ .

- **Objective:** minimize (external) regret

$$\text{Reg}_T = \sum_{t=1}^T L(h_t(x_t), y_t) - \min_{h \in H^*} \sum_{t=1}^T L(h(x_t), y_t).$$

# Apprentissage en-ligne

- Apprentissage en ligne:

- On reçoit l'entrée  $x_t$
- On choisit un classifieur  $h_t$
- L'environnement choisit  $y_t$
- On souffre de la perte  $L$

$$\text{Reg}_T = \sum_{t=1}^T L(h_t(x_t), y_t) - \min_{h \in H^*} \sum_{t=1}^T L(h(x_t), y_t).$$

- Résumé:

- L'environnement a tout les pouvoirs.
- On ne peut plus minimiser la perte.
- On peut minimiser le regret (si la tâche était trop dure alors on a rien a regretter)

- En pratique:

- **Risqué car potentiellement instable avec de l'apprentissage profond.**  
**(sauf avec des modèles simples qui ont des garanties)**

# Peut-on trouver un juste milieu?

- Apprentissage hors ligne (sur l'ensemble des données passées) est plus stable
  - Ne capture pas les changements de distribution
  - Peut-on le combiner avec l'apprentissage en ligne?
- Oui: Minimisation répétée
  - Entraîner sur les données passées
  - Évaluer le modèle
  - Déployer le modèle
  - Collecter de nouvelles données (ne pas les utiliser en ligne)
  - Répéter

## Deux exemples en pratique

- Prediction performative
- Adapation aux données test sans étiquettes.

# Apprentissage de données statiques

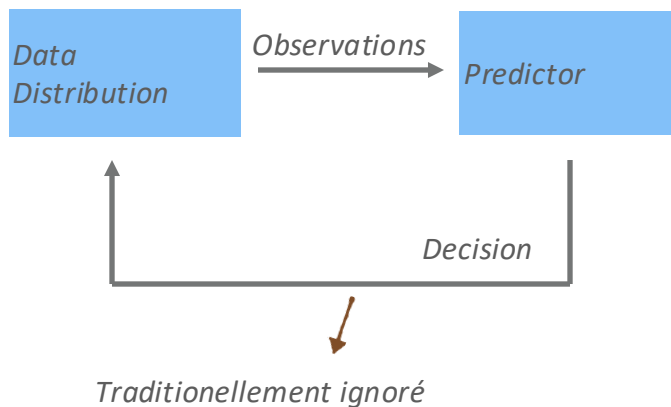
Mais dans de nombreuses applications, la distribution va changer. En particulier les nouvelles données peuvent dépendre du modèle déployé.



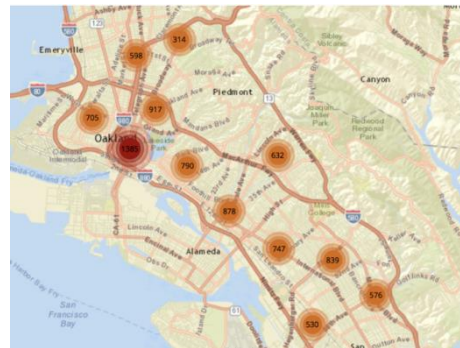


## Learning from Decision-dependent data

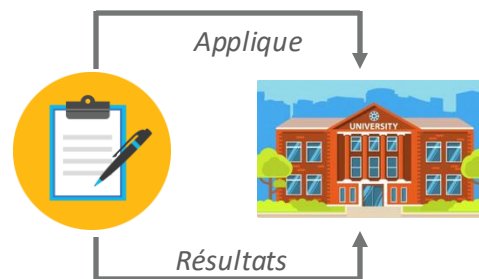
*Fermer la boucle!*



**Performativité:** La distribution des données dépend du modèle



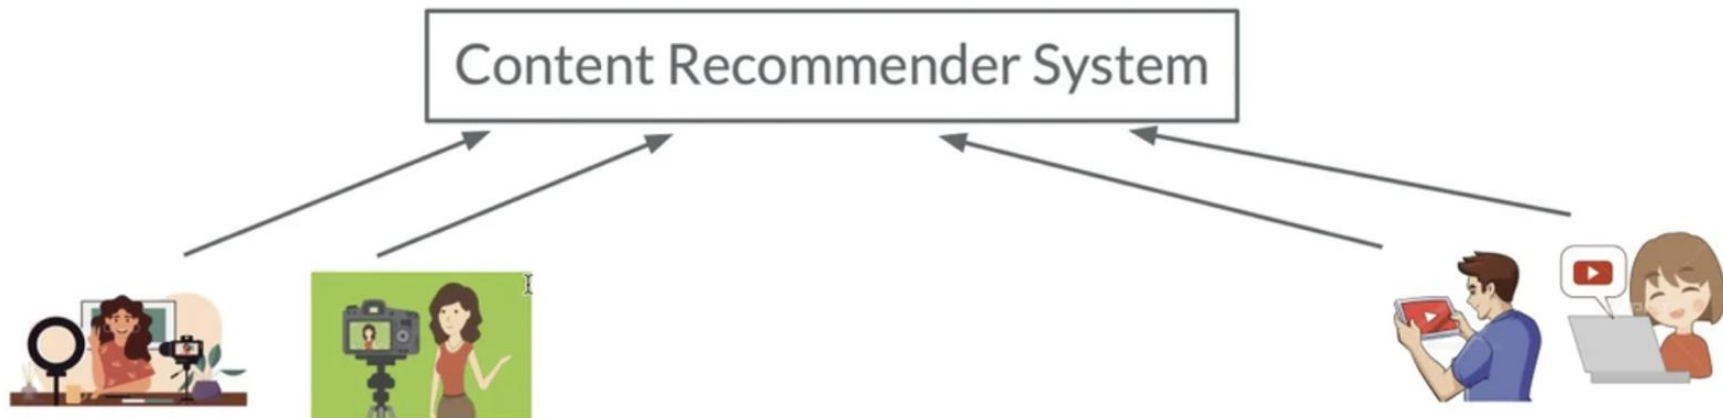
*Prédiction de crime*



*Admission*

# Social Impact of Algorithmic Decisions

Algorithmic decisions can *shape* the marketplace where they are deployed.



## Minimisation du risque répétée:

- La distribution à l'étape  $t$  dépend du classifieur déployé au temps précédent

$$\theta_{t+1} = \arg \min_{\theta} \mathbf{E}_{(x,y) \sim p_{\theta_t}} [\ell(f_{\theta}(x), y)]$$

- La performance après déploiement est différente de la performance mesurée avant le déploiement:

$$\mathbb{E}_{(x,y) \sim p_{\theta_t}} [\ell(f_{\theta_t}(x), y)] \neq \mathbb{E}_{(x,y) \sim p_{\theta_{t+1}}} [\ell(f_{\theta_t}(x), y)]$$

# Equilibre

- Lorsque le modèle induit la distribution sur laquelle il a été appris on a atteint la stabilité.

$$\theta_* = \arg \min_{\theta} \mathbb{E}_{(x,y) \sim p_{\theta_*}} [\ell(f_{\theta}(x), y)]$$

- En pratique: Important de monitorer le modèle pour détecter les baisses de performance (et réentraîner!)

# Adaptation sans étiquettes

- Vous entraîner votre modèle sur un jeu de données classique
  - Vous deployer votre modèle sur un tâche réelle.
  - Des données arrivent après le déploiement.
  - Elles correspondent parfaitement à la tâche!
  - Problème: **pas d'étiquettes**
- 
- Comment les utiliser ?

# Idée: générer les étiquettes avec le modèle

- Pseudo étiquettes:  $\hat{y} = f_{\theta}(x^t)$ .
- Ne marche que si le modèle est bon à la base!

Published as a conference paper at ICLR 2021

---

## TENT: FULLY TEST-TIME ADAPTATION BY ENTROPY MINIMIZATION

**Dequan Wang<sup>1\*</sup>, Evan Shelhamer<sup>2\*†</sup>, Shaoteng Liu<sup>1</sup>, Bruno Olshausen<sup>1</sup>, Trevor Darrell<sup>1</sup>**

dqwang@cs.berkeley.edu, shelhamer@google.com

UC Berkeley<sup>1</sup>    Adobe Research<sup>2</sup>

# Conclusion

- Series temporelles:
  - Utiliser l'hypothèse de Markov!
  - Les valeurs du passé sont utiles pour prédire le futur
  - Important de vérifier que la distribution est stationnaire!
- Non-stationnarité de la distribution
  - Peut être du à
    - Changement saisonaux
    - Performativité
  - Important de monitorer les performances des modèles déployé
  - Ré-entraîner (finetune) quand nécessaire.
  - On peut utiliser le modèle courant pour générer des pseudo-labels (attention risqué)

# References

- <https://www.taylorfrancis.com/books/mono/10.1201/9781420010893/hidden-markov-models-time-series-walter-zucchini-iain-macdonald>
- [https://cims.nyu.edu/~mohri/aml/aml\\_time\\_series.pdf](https://cims.nyu.edu/~mohri/aml/aml_time_series.pdf)
- <https://www.slideshare.net/DerekKane/data-science-part-x-time-series-forecasting>
- <https://www.analyticsvidhya.com/blog/2021/10/a-comprehensive-guide-to-time-series-analysis/>